

Open-Notebook 项目探索与改进总结

3.28 - 4.4

吴炜航

Day 1: 模型适配优化与前端路由升级兼容

核心目标：解决特定大模型接口限制与框架版本升级带来的阻断问题

嵌入模型并发与限流改造

针对 `text-embedding-v4` 模型的 **batch size** 限制，将 `EMBEDDING_BATCH_SIZE` 调整为 `10`，并引入 `asyncio.sleep` 缓冲机制，降低请求并发压力，提升嵌入处理的稳定性。

Next.js 15+ 动态路由修复

修复 `params Promise` 报错问题，通过 `React.use()` 对异步路由参数进行解包，完成对 **Next.js 15+** 动态路由写法的兼容升级。

Day 2: 上下文构建器 (ContextBuilder) 逻辑重构

核心目标：突破系统原有信息隐匿瓶颈，确保大模型获取完整文档知识

隐秘逻辑排查与溯源

深入溯源底层**Domain**层代码，发现系统在短上下文模式下默认隐式丢弃**full_text**的行为

构建器机制重写

强行重构**ContextBuilder**的参数透传逻辑，加载大模型生成的洞察与整个文档的**raw_text**

极限容量放宽

匹配**128k**超大上下文模型能力，将原文字符截断阈值放宽至**50,000**字符，提升单文档深度问答精度

Day 3: 单/多文档对话的全双工流式输出 (SSE) 改造 (后端)

核心目标：彻底告别"转圈等待"，实现逐字打字的极速交互体验

LangGraph异步死锁破除

深挖底层执行图，将同步阻塞的
`model.invoke`重构为`await`
`model.ainvoke`与全异步节点函数

状态机异步化替换

将同步`SqliteSaver`全面替换为基于
`aiosqlite`的`AsyncSqliteSaver`，保障
断点记忆功能的并发安全

代理缓冲层击穿

引入标准**Server-Sent Events**流，
强行打入**X-Accel-Buffering**标头，
击穿代理与浏览器的静默超时缓冲机制

Day 4: 全局流式响应前端对接与核心状态实时更新

核心目标：完成流式基建的最后一公里，并赋予 **UI** 实时响应能力

前端流式解析引擎重构

在 **useSourceChat** 和 **useNotebookChat** 钩子中重构 **fetch** 与 **ReadableStream** 逻辑，实现 **SSE** 数据块的缓冲拼接、不完整行防撕裂处理、事件类型鉴别与打字机 **UI** 状态的渐进式刷新

来源列表状态实时化

设计混合更新机制：事件驱动刷新（新建/更新/删除后广播 **sourcesUpdated** 事件）+ 智能静默轮询（**5秒** 间隔后台轮询，利用 **ID** 匹配智能合并文档 **processing** 状态与 **insights_count** 进度）

Day 5: 深度 Ask 模式流式攻坚与多模态实验回滚

核心目标：解决深度推理模型的兼容性卡死，完善系统多模态解析边界

DeepSeek-R1推理模型流式兼容

排除Ask模式请求长期卡死的原因：DeepSeek-R1等深度推理模型不兼容强约束的**JSON Structured Output API**，通过剥离结构化类型约束彻底解决API挂起问题

底层Token级深度流式捕获

在Ask模式中启用LangGraph的**astream_events(version="v2")**，实现对模型深层思考过程（<think>）的精准捕获，扩展前端事件解析器对**strategy_reasoning_chunk**的高保真打字机渲染

多模态识别功能剥离

清理并移除Docling解析层中的"图片单独提取并调用VLM大模型二次描述"功能，系统恢复为轻量级纯文本极速解析模式

架构演进调研

详尽梳理Ask模式内部的查询分解与向量检索机制，为未来引入SurrealDB知识图谱检索（**Graph RAG**）提供理论基础与架构设计建议

Day 6: Open-Notebook 核心对话模式数据流与检索逻辑梳理

核心目标：系统化梳理三大对话模式的数据流向与检索机制（流式输出为原创优化）

单文档对话模式 (Source Chat)

无动态检索，采用全量上下文加载。
系统加载文档的所有见解与完整原文，
通过字符阈值截断机制防止超出
Token上限，最后通过**SSE**流式输出

普通多文档对话模式 (Notebook Chat)

无动态检索，完全基于前端显式勾选
内容。用户在前端选择来源与深度，
后端直接拼接合并所有文档内容，一
次性打包发送给**Chat**模型

Ask提问模式 (Ask Knowledge Base)

Agent任务拆解+分发检索+局部萃
取综合的**Multi-step RAG**架构。包
含策略规划、并发检索与信息萃取、
最终融合生成三个阶段，支持双轨流
式传输展示思考过程与最终答复