

Open-Notebook 知识图谱功能探索与改进总结

截至 4.12

吴炜航

Day 1: 本体库定义与底层图数据库架构设计

核心目标: 确立科研领域的数据模型结构, 搭建底层存储基建

主要工作:

- 动态本体库配置: 在 **.env** 中设计定制化科研领域本体库, 定义 **8** 大实体类型 (**MATERIAL, CHEMICAL, EXPERIMENT, RESULT** 等) 及关系类型, 通过全局开关 **ENABLE_KNOWLEDGE_GRAPH=true** 实现功能灵活插拔
- **SurrealDB Schema** 规划: 编写迁移脚本 (**15.surrealql**), 定义 **kg_entity** 节点表 (含倒排索引支持全文本检索) 和 **kg_relation** 边表, 确保底层图结构严谨映射科研实体关联

Day 2: 大模型驱动的知识图谱全量抽取管线构建

核心目标: 利用 **LLM** 强大的理解能力, 精准、结构化地提取长文本关系

主要工作:

超长上下文全篇抽取

摒弃传统文本切块策略, 依托 **Qwen** 模型 **60k tokens** 超长输出能力, 将 **max_tokens** 放宽至 **60000**, 实现全文单次过账图谱抽取, 避免切块导致的关系断裂

Prompt 工程与枢纽节点设计

深度优化
prompts/kg/extraction.jinja, 独创性引入 **EXPERIMENT** 作为枢纽节点设计模式, 解决一个实体与多个实验数据关联时的图结构混乱问题, 加入防幻觉的数值歧义过滤规则

容错与格式约束

结合 **LangGraph** 与 **PydanticOutputParser**, 强制 **LLM** 输出严格符合 **Pydantic Schema** 定义的 **JSON** 结构, 增加节点完整性防线

Day 3: 实体消歧、数据并发写入与级联一致性保障

核心目标: 解决图数据落库时的并发冲突与生命周期管理痛点

实体消歧与 UPSERT 逻辑

实现 **slugify** 算法, 基于实体名称和类型生成全局唯一的 **ID**, 并在入库时采用 **UPSERT** 操作, 确保相同实体在不同文档间能够正确融合

SurrealDB 并发事务冲突修复

在压测图谱抽取写入时, 发现 **asyncio.gather** 带来的高并发会导致 **SurrealDB** 底层报读写事务冲突。迅速将批量异步写入重构为顺序 **for** 循环同步写入, 彻底根除该报错

类型安全与级联删除

解决底层 **Type Mismatch Bug**, 强制在 **SurrealQL** 语句中加入 **<string> \$source_id** 的显式类型转换, 同时增加针对图谱节点和边的级联删除逻辑, 杜绝"幽灵节点"

Day 4: Hybrid RAG (向量 + 图谱) 混合检索融合

核心目标：无缝接入现有的 **Ask** 模式，极大提升跨步推理准度

主要工作：

Subgraph Expansion (子图扩展) 算法：

在后端的 `domain/notebook.py` 中实现专属的 **graph_search** 逻辑。首先利用 **BM25** 文本匹配找到相关的"入口节点"，然后自动进行 **1-hop** 的边遍历，将关联的上下文一并召回

透明的混合检索架构：

对大模型而言，搜索词依然是基于自然语言（如 **4** 个关键词策略）。系统在底层对每一个关键词并行发起向量检索和图谱检索，然后将两者的结果无缝拼接交由下游的应答模型处理，实现了不需要修改前端交互逻辑的"静默强化"

Day 5: 前端 UI 状态集成与实时响应优化

核心目标: 让后端的复杂处理流程在前端完全可视化, 保障用户体验

主要工作:

状态展示列扩展: 在"所有来源"页面 (`sources/page.tsx`) 增加"已抽取图谱"专属列, 并根据后端 **API** 数据精准映射图谱的生成状态

事件驱动的实时刷新: 修复了前端需要手动刷新才能看到最新解析状态的 **Bug**。通过在 **React Query** 的 **mutations** 中派发全局 **sourcesUpdated** 自定义事件, 配合前端 **5** 秒级的智能轮询, 实现了状态的实时可视化更新

UI 呈现回归极简: 积极响应用户反馈, 去除了多余的"处理中..."动态展示, 恢复了极简明确的"是/否"静态徽章, 保证了前端视觉的克制与整洁

Day 6: 品牌迭代、系统优化与并行处理架构升级

核心目标：精简产品功能、优化系统性能、实现任务全并行化

主要工作分为两部分：

第一部分 - 界面与配置精简：

- **界面精简：**从侧边导航栏和快捷命令面板（Cmd+K）中移除了"播客"功能的入口
- **配置简化：**移除模型配置页中的"默认语音转文本 (STT)"和"默认文本转语音 (TTS)"选项
- **品牌替换：**将各类提示、错误页面及多语言包中的"Open Notebook"文案统一替换为"Lumina"，并清理了指向原 GitHub 仓库的说明文档链接
- **日志降噪：**关闭了 Uvicorn 的默认 HTTP 访问日志（Access Log），防止前端高频轮询状态时产生的大量无意义 GET 请求刷屏控制台

第二部分 - 事件循环与并行处理优化：

- **异步线程化：**将 CPU 密集型的文档提取操作 (extract_content) 放入 asyncio.to_thread 执行，彻底解决主事件循环被阻塞导致的 SurrealDB WebSocket 连接超时问题
- **工作流解耦：**重构了 process_source 工作流，将见解生成 (transform_content) 解耦为异步后台任务 (run_transformation)，实现见解生成、向量嵌入和知识图谱抽取的完全并行执行
- **上下文扩展：**将 transformation.py 中的 max_tokens 限制从 8192 提升至 60000，确保大模型能一次性处理未分片的长文档全文
- **预检机制：**在 API 路由层 (api/routers/sources.py) 增加了 AI 模型存在的预检机制，防止因模型未配置导致后台任务队列永久卡死
- **可观测性增强：**增加了知识图谱抽取的进度日志，修改了前端 API 密钥设置页的帮助链接指向 GitHub 仓库首页